

GERAÇÃO SIMBÓLICA DE MELODIAS NO ESTILO CORAL DE BACH COM CADEIAS DE MARKOV DE ORDEM N

Erick Soares de Souza
Universidade Federal de Minas Gerais
ericksoares@dcc.ufmg.br

RESUMO

Este trabalho apresenta um sistema de geração simbólica de melodias baseado em Cadeias de Markov de ordem n , treinado sobre a voz do baixo dos 371 corais a quatro vozes (SATB) de J.S. Bach distribuídos com a biblioteca `music21`, adotados como restrição estilística. Entre as quatro vozes, o baixo é escolhido por ser a mais ativa, com maior salto melódico médio e maior densidade rítmica, e todas as peças são normalizadas para Dó maior antes do treino, de modo a concentrar a aprendizagem nos padrões melódicos relativos ao estilo. Os tokens representam eventos de pitch e duração no formato `Pitch: dur`, além de pausas (`R: dur`) e marcadores de compasso (`BAR`). Dois hiperparâmetros principais são explorados: a ordem $n \in \{1, 2, 3\}$, que define a memória do modelo, e a temperatura $T \in \{0,5; 1,0; 1,5\}$, que controla a diversidade da amostragem. Para avaliar objetivamente a fidelidade estilística, as 9 combinações resultantes são comparadas estatisticamente, com 5 sementes cada, ao corpus real por meio de entropia de pitch, proporção de movimento por grau conjunto, intervalo médio e divergência de Kullback-Leibler (KL) da distribuição de intervalos. Os resultados indicam que a ordem 2 com $T = 1,0$ é a configuração mais fiel ao estilo de Bach, com a menor divergência KL entre todas (0,022), equilibrando fidelidade estatística e diversidade. O código está disponível em <https://github.com/ericksoares13/DCC831-TP1>.

1. INTRODUÇÃO

A geração algorítmica de música simbólica, isto é, a geração de sequências de eventos musicais discretos como notas e pausas, é um problema clássico de inteligência artificial aplicada à música, discutido por Ames (1989) [1]. Entre os modelos probabilísticos propostos para essa tarefa, as Cadeias de Markov destacam-se pela interpretabilidade, pela facilidade de treinamento e pela capacidade de produzir resultados musicalmente inteligíveis mesmo em ordens baixas.

Neste trabalho, adota-se o estilo coral de Bach como restrição estilística, explorando um corpus de grande porte

e estilisticamente coeso, o conjunto de 371 corais a quatro vozes distribuído com a biblioteca `music21`. A voz do baixo, detalhada na Seção 3, é utilizada como linha de treinamento, com normalização tonal aplicada para reduzir o viés de tonalidade original de cada peça.

O sistema proposto é inspirado no trabalho de Shapiro & Huber (2021) [2], estendido para ordem $n > 1$, amostragem com temperatura e um corpus de maior escala, 371 corais, contra um único arquivo por instrumento em Shapiro & Huber. Diferentemente da avaliação qualitativa desses autores, este trabalho também conduz uma avaliação quantitativa sistemática frente ao corpus real (Seção 4).

2. TRABALHOS RELACIONADOS

Ames (1989) [1] fornece o panorama fundacional do uso de Cadeias de Markov como modelo composicional. O autor classifica os modelos por ordem e discute o compromisso entre memorização do corpus e generalização criativa, argumento que guia diretamente a escolha de ordem adotada. O artigo demonstra que já na ordem 1 emergem estruturas musicalmente reconhecíveis, enquanto ordens elevadas tendem à reprodução literal de trechos do corpus.

Shapiro & Huber (2021) [2] são a referência técnica direta deste trabalho. Os autores implementam um gerador de ordem 1 treinado sobre trechos de MusicXML de um único instrumento por corpus. A abordagem aqui apresentada expande esse método para ordem n , temperatura controlável e um corpus de maior escala (371 corais de Bach), mantendo a mesma estrutura de Parser/Generator e os mesmos nomes de funções.

Pachet (2003) [3] apresenta o *Continuator*, sistema iterativo de improvisação que aprende o estilo do músico em tempo real via Cadeias de Markov de ordem variável, navegando o espaço de estados sem fixar a ordem *a priori* e evitando o compromisso ordem-generalização. Diferentemente, a abordagem adotada usa ordem fixa, mais simples de inspecionar e justificar em um contexto didático.

Conklin & Witten (1995) [4] propõem os *Multiple Viewpoint Systems*, nos quais múltiplas cadeias de Markov operam sobre representações diferentes da música (pitch, intervalo, contorno, duração), e suas probabilidades são combinadas. Essa abordagem mitiga a esparsidade de estados de ordem elevada, problema observado experimentalmente mesmo num corpus estilisticamente homogêneo como o dos corais (Seção 4). Uma extensão natural do



método proposto seria adotar múltiplos pontos de vista.

Pearce & Wiggins (2004) [5] estendem o trabalho de Conklin & Witten com o modelo IDyOM, que seleciona a ordem adaptivamente com base na entropia local da sequência. Esse mecanismo seria especialmente valioso no contexto deste estudo, já que a esparsidade cresce rapidamente com a ordem mesmo dentro de um corpus coeso, sugerindo que uma ordem adaptativa equilibraria melhor fidelidade e generalização música a música.

3. MÉTODO

3.1 Conjunto de Dados e Pré-processamento

É utilizada a voz do baixo dos 371 corais a quatro vozes de J.S. Bach distribuídos com o `music21`, acessados diretamente via `music21.corpus`. Essa voz é escolhida, entre as quatro, por ser a mais ativa, apresentando salto melódico médio de 3,10 semitons e 47% de notas com duração menor que um tempo, contra 1,7–2,0 semitons e 19–42% nas demais vozes, medido sobre o dataset inteiro. Um pequeno número de corais não tem a voz anotada por nome e, nesses casos, como todo coral a quatro vozes lista soprano/alto/tenor/baixo nessa ordem, a última voz é usada como alternativa. Cada peça é convertida com `music21`, de modo que as notas são extraídas com seus offsets e durações expressas em *quarter lengths*. Aplica-se normalização tonal (`normalize_key`), em que a tonalidade é detectada por `music21.analysis.discrete` e todas as notas são transpostas para Dó maior/lá menor antes da tokenização. Um cache em disco evita reprocessamento, já que processar o dataset inteiro com o `music21` leva cerca de 75 segundos.

3.2 Representação por Tokens

Cada evento musical é mapeado para um token de texto: nota (G4:1.0, pitch em notação científica e duração em *quarter lengths*), pausa (R:0.5, silêncio com a duração indicada) e compasso (BAR, marcador de barra de compasso), guiando a geração pela estrutura de frases do estilo. Como a voz do baixo é essencialmente monofônica, múltiplas notas simultâneas praticamente não ocorrem. Por segurança, mantém-se ainda assim a regra de reduzir qualquer sobreposição à nota mais aguda, evitando que uma eventual sobreposição pontual exploda o espaço de estados em vez de ser tratada como uma nota só. A sequência de tokens de cada peça constitui, assim, uma *frase de treinamento* para o modelo.

3.3 Cadeia de Markov de Ordem n

Seguindo Shapiro & Huber (2021) [2], a estrutura de dados central é um dicionário esparsos de transições. Para cada estado (janela de n tokens consecutivos), armazena-se a contagem de cada sucessor observado no corpus, e após o treinamento essas contagens são normalizadas em probabilidades.

A inicialização usa a distribuição acumulada de estados iniciais (CDF) e a função `find_nearest_above`,

que retorna o primeiro estado cuja probabilidade acumulada ultrapassa um valor sorteado, idêntica à de Shapiro & Huber (2021) [2]. As transições seguintes usam `random.choices`, função do Python que sorteia um elemento proporcionalmente a pesos dados, equivalente ao método da CDF para $T = 1$. Quando a janela atual não tem sucessor observado, mais comum em ordens altas (Seção 4), a geração reinicia a partir da distribuição de estados iniciais. Shapiro & Huber, nessa situação, encerram o programa.

3.4 Temperatura

Antes da amostragem, os pesos de transição são reescalados:

$$w'_i = w_i^{1/T}, \quad T > 0. \quad (1)$$

Para $T < 1$ o modelo favorece transições mais prováveis, ficando mais conservador, enquanto para $T > 1$ a distribuição se uniformiza, ficando mais criativo. Em $T = 1$ o comportamento reproduz o de Shapiro & Huber.

3.5 Síntese MIDI

Ao converter a sequência de tokens gerada em um arquivo MIDI, duas correções são aplicadas. Cada pitch é restrito à tessitura do piano (21–108), transpondo por oitavas quando necessário, já que normalização tonal ou notas atípicas do dataset podem gerar pitches fora desse intervalo. Além disso, a velocidade MIDI de cada nota segue um envelope senoidal por frases de 8 notas, com decaimento global de 10% ao longo da peça, substituindo o volume fixo (100) de Shapiro & Huber por uma dinâmica que sugere fraseado musical.

4. RESULTADOS

Treinado sobre as 371 peças, usando a voz do baixo normalizada para Dó maior/lá menor, o vocabulário de tokens distintos é de 180 estados. O número de chaves de transição cresce com a ordem, sendo 180 em ordem 1, 1861 em ordem 2 e 6644 em ordem 3, o que evidencia a esparsidade crescente mesmo num corpus estilisticamente homogêneo. A normalização tonal reduz esse número em todas as ordens, 1861 contra 2155 chaves em ordem 2 e 6644 contra 7873 em ordem 3 sem normalização, confirmando que concentrar as peças em uma única tonalidade central reduz a fragmentação de padrões equivalentes transpostos.

Para avaliar a fidelidade estilística, são geradas as 9 combinações de ordem ($n \in \{1, 2, 3\}$) e temperatura ($T \in \{0,5; 1,0; 1,5\}$), com 5 sementes cada (200 tokens, 80 BPM), comparadas estatisticamente com os 371 corais reais (mesma voz, mesma normalização). As métricas usadas incluem entropia de Shannon do pitch (H), proporção de intervalos de até 2 semitons (*steps*, limiar de cantabilidade), intervalo melódico médio absoluto, proporção de tokens de pausa/compasso, divergência KL entre a distribuição de intervalos gerada e a real, e o desvio médio em σ (mean- z) em relação à variabilidade observada entre os próprios corais. A Tabela 1 resume os resultados, com a

primeira linha trazendo os valores de referência do corpus real (média por coral).

Table 1. Métricas vs. corpus real (371 corais, 9 configurações, 5 sementes cada).

Ord	T	H	Steps	Ivl μ	Pausas	z	KL
Bach		4,241	66,1%	3,249	21,1%	0,00	0,000
1	0,5	4,152	70,3%	3,097	25,2%	0,50	0,079
1	1,0	5,069	57,1%	4,138	23,4%	2,16	0,149
1	1,5	5,441	55,1%	4,555	16,7%	2,85	0,208
2	0,5	4,575	70,3%	3,132	28,8%	0,90	0,041
2	1,0	4,820	67,3%	3,129	22,2%	1,22	0,022
2	1,5	5,110	62,7%	3,396	20,4%	1,63	0,025
3	0,5	4,793	64,3%	3,546	25,9%	1,31	0,023
3	1,0	4,978	62,7%	3,464	22,8%	1,48	0,034
3	1,5	5,013	62,9%	3,598	23,4%	1,65	0,029

Em termos de fidelidade, a ordem 2 com $T = 1,0$ é a configuração mais próxima do corpus real pela distribuição de intervalos, com a menor divergência KL entre todas (0,022). Seu intervalo médio, 3,13 contra 3,25 semitons reais, e sua proporção de steps, 67,3 % contra 66,1 % reais, ficam dentro de 1σ do corpus, e a proporção de pausas, 22,2 % contra 21,1 % reais, é quase idêntica, sendo a única configuração que acerta ambos simultaneamente.

Quanto à relação entre ordem e fidelidade, as ordens 2 e 3 produzem distribuições de intervalo muito mais próximas do real que a ordem 1, cujo $T = 1,5$ chega a $KL = 0,208$, nove vezes maior que o de $O2+T1,0$. Isso ocorre porque a cadeia de ordem 1 aprende transições isoladas e, com temperatura alta, passa a gerar saltos de $7^\circ/8^\circ$ que Bach raramente usa, enquanto as ordens 2–3 preservam contexto suficiente para restringir os saltos a regiões musicalmente plausíveis do estilo.

Já o efeito da temperatura é assimétrico entre ordens. Em ordem 1, $T = 1,5$ causa colapso de fidelidade, com intervalo médio de 4,55 semitons e só 55 % de steps, ao passo que em ordens 2–3 o efeito é suave, com o KL de ordem 2 subindo apenas de 0,022 ($T=1,0$) para 0,025 ($T=1,5$), ainda dentro de 1σ . Isso indica que a temperatura só introduz diversidade genuína quando há contexto suficiente, enquanto em ordem 1 ela introduz principalmente ruído.

Analisando-se a entropia, nota-se que maior fidelidade não implica menor entropia. A configuração mais próxima globalmente por mean- z ($O1+T0,5$, mean- $z = 0,50$) tem a menor entropia, 4,15 bits, mais perto dos 4,24 reais, enquanto $O2+T1,0$ tem entropia maior, 4,82 bits, $2,0\sigma$ acima, e ainda assim é a mais fiel pelos intervalos. A razão é que Bach usa uma distribuição de pitch não uniforme, em que tônica, dominante e subdominante dominam, e a ordem 2 distribui alturas de forma mais homogênea, mas preserva os intervalos preferenciais do estilo (graus conjuntos, quartas/quintas).

Observa-se também uma saturação em ordem 3. De $T=1,0$ para $T=1,5$, o KL cai ($0,034 \rightarrow 0,029$) e a entropia varia só 0,04 bits, já que, com contexto de 3 tokens, o espaço de transições é tão restrito que a temperatura extra redistribui peso entre opções igualmente raras, sem acrescentar diversidade real.

Em suma, ordem 2 com $T=1,0$ é a configuração re-

comendada, com $KL = 0,022$, ordem 1 com $T=0,5$ serve de referência conservadora, com menor variância e entropia mais próxima da real, e ordem 1 com $T=1,5$ ilustra divergência máxima, com $KL = 0,208$, saltos frequentes e pouca estrutura frásica.

5. DISCUSSÃO E TRABALHOS FUTUROS

5.1 Limitações

A principal limitação está na natureza das métricas empregadas. Entropia, divergência KL e mean- z capturam estatísticas agregadas de pitch e intervalo, mas não avaliam estrutura musical de mais alto nível, como frase, cadência ou forma. Uma avaliação perceptual complementar, idealmente com ouvintes de formação musical, ainda seria valiosa para validar essas conclusões. O autor, sem essa formação, apoiou a análise sobretudo nas métricas objetivas por esse motivo.

Duas outras limitações vêm da representação escolhida. O sistema gera linhas sem harmonização, mesmo treinado sobre um repertório harmonizado, já que o baixo é só uma das quatro vozes de cada coral, o que restringe a percepção musical do resultado a uma única linha melódica. Já as notas simultâneas na voz do baixo são reduzidas à nota mais aguda, embora isso seja raro nesse tipo de voz predominantemente monofônica.

Por fim, a normalização tonal força todas as peças para Dó maior, perdendo a identidade tonal original em favor da concentração estatística nos padrões melódicos relativos. Uma alternativa seria normalizar apenas os intervalos, preservando o modo.

5.2 Trabalhos Futuros

Uma extensão imediata é adotar a abordagem de múltiplos pontos de vista de Conklin & Witten (1995) e Pearce & Wiggins (2004) [4, 5], combinando cadeias sobre pitch, intervalo e duração para mitigar a esparsidade de estados de ordem elevada. Outra direção natural, dado que o corpus já contém as quatro vozes de cada coral, é condicionar a cadeia do baixo às demais vozes (soprano, alto, tenor) como harmonização, análogo ao Continuator de Pachet (2003) [3], mas guiado pela harmonia real de Bach, não por interação em tempo real. Por fim, modelos de linguagem musical como Music Transformer, Coconet ou DeepBach oferecem um patamar comparativo natural para avaliar o ganho das abordagens neurais sobre o baseline Markoviano.

6. DECLARAÇÃO DE USO DE IA

Este trabalho utilizou assistência de IA generativa (Claude, Anthropic), via *Claude for Scientists*, como apoio na implementação do código, na análise quantitativa dos resultados e na revisão do resumo. Detalhes do uso e o acesso às conversas estão declarados no README do repositório (<https://github.com/ericksoares13/DCC831-TP1>).

7. REFERENCES

- [1] C. Ames, “The Markov process as a compositional model: A survey and tutorial,” *Computer Music Journal*, vol. 13, no. 4, pp. 30–56, 1989.
- [2] N. Shapiro and H. Huber, “Markov chains in the generation of music,” 2021, projeto acadêmico, Harvey Mudd College.
- [3] F. Pachet, “The continuator: Musical interaction with style,” *Journal of New Music Research*, vol. 32, no. 3, pp. 333–341, 2003.
- [4] D. Conklin and I. H. Witten, “Multiple viewpoint systems for music prediction,” *Journal of New Music Research*, vol. 24, no. 1, pp. 51–73, 1995.
- [5] M. T. Pearce and G. A. Wiggins, “Improved methods for statistical modelling of monophonic music,” *Journal of New Music Research*, vol. 33, no. 4, pp. 367–385, 2004.